

Boolean Model → No Ranking

Ex. $D1 = (0.8A, 0.5B, 0.6C)$ * and 1% min

$D2 = (0.4A, 0.5B, 0.1C, 0.8D)$ or 1% max

Query : $(0.5A \text{ and } 0.2B) \text{ or } (\text{not } D \text{ or } 0.3C)$

	A and B	Not D	Relevance
D1	$\min(0.5 \times 0.8, 0.2 \times 0.5) = 0.1$	$\max(1, 0.3 \times 0.6) = 1$	$\max(0.1, 1) = 1$
D2	$\min(0.5 \times 0.4, 0.2 \times 0.4) = 0.08$	$\max(0.2, 0.3 \times 0.1) = 0.2$	$\max(0.08, 0.2) = 0.2$

Vector Model → ไม่ใช้ doc. = ขอบเขตข้อมูล

query weight : $w_{i,q} = (0.5 + 0.5 \frac{tf_{iq}}{\max tf_{iq}}) \times idf_i$

doc weight : $w_{ij} = tf_{ij} \times idf_j$

similarity score : $\text{sim}(q, d_i) = \frac{\sum w_{q_i} w_{d_{ij}}}{\sqrt{\sum (w_{q_i})^2} \sqrt{\sum (w_{d_{ij}})^2}}$

kw/doc : $tf_{ij} = \text{freq} / \max \text{freq}$

All Doc / kw Doc : $idf_i = \log(N/n_i)$

Ex. Query = "cat dog tiger cat"

	Bird	Cat	Dog	Tiger	Max
Doc1	3	2	2	0	3
Doc2	0	2	1	1	2
Doc3	2	0	1	0	2
Doc4	0	1	0	1	1
Doc5	0	1	1	3	3
Doc6	3	2	0	2	3
Doc7	1	1	1	1	1
Doc8	1	1	1	0	1
Doc9	0	1	1	1	1
Doc10	0	0	0	3	3
n	5	8	7	7	

→ คำนวณ tf และ idf

1) หา w_{ij} จาก tf_i , idf_j

idf_{bird} = $\log(10/5) = 0.301$
idf_{cat} = $\log(10/8) = 0.097$
idf_{dog} = $\log(10/7) = 0.155$
idf_{tiger} = $\log(10/7) = 0.155$

พจน์ doc ใน doc weight

Doc1 : $tf_{bird} = 3/3 = 1$

$tf_{cat} = 2/3 = 0.67$

$tf_{dog} = 2/3 = 0.67$

$tf_{tiger} = 0/3 = 0$

2) คำนวณ w ทุก doc

Doc1 : $w_{bird,1} = 1 \times 0.301 = 0.301$

$w_{cat,1} = 0.67 \times 0.097 = 0.065$

$w_{dog,1} = 0.67 \times 0.155 = 0.103$

$w_{tiger,1} = 0 \times 0.155 = 0.000$

สามารถทำใน excel ได้
เพราะใช้สูตรเดียวกัน ทุกค่า

3) คำนวณ w ของ query

$w_{bird,q} = (0.5 + 0.5(0/3)) \times 0.301 = 0.151$

$w_{cat,q} = (0.5 + 0.5(2/3)) \times 0.097 = 0.097$

$w_{dog,q} = (0.5 + 0.5(2/3)) \times 0.155 = 0.117$

$w_{tiger,q} = (0.5 + 0.5(0/3)) \times 0.155 = 0.117$

4) คำนวณ sim ระหว่าง doc

$\text{sim}(d_i, q) = \frac{(0.151)(0.301) + (0.097)(0.065) + (0.117)(0.103)}{\sqrt{(0.151^2 + 0.097^2 + 0.117^2)(0.301^2 + \dots + 0^2)}}$
= 0.806

5) Ranking ด้วย sim จากสูง

	Bird	Cat	Dog	Tiger	Max
Doc1	0.301	0.065	0.103	0.000	
Doc2	0.000	0.097	0.077	0.077	
Doc3	0.301	0.000	0.077	0.000	
Doc4	0.000	0.097	0.000	0.155	
Doc5	0.000	0.032	0.052	0.155	
Doc6	0.301	0.065	0.000	0.103	
Doc7	0.301	0.097	0.155	0.155	
Doc8	0.301	0.097	0.155	0.000	
Doc9	0.000	0.097	0.155	0.155	
Doc10	0.000	0.000	0.000	0.155	
q	0.151	0.097	0.117	0.117	

Fuzzy Logic → kw มี doc. , ค่า doc. 0-1

complement : $\mu_{\bar{A}}(x) = 1 - \mu_A(x)$

Intersection : $\mu_{A \cap B} = \mu_A(x) \cdot \mu_B(x)$

Union : $\mu_{A \cup B} = 1 - (1 - \mu_A(x)) \cdot (1 - \mu_B(x))$

doc. kw i, j : $c_{ij} = n_{ij} / (n_i + n_j - n_{ij})$ n = จำนวนเอกสาร
= มีทั้ง i, j

Ex. Query = "ขอเอกสารที่มี cat หรือ kitty
แต่ไม่มีเอกสารที่มี dog"

D1 : {bird, cat, bird, cat, tiger, kitty, fish, fish}

D2 : {cat, dog, tiger, zoo}

D3 : {house, kitchen, bird, bird, cat, cat, kitty}

D4 : {dog, rubber, house, dog}

D5 : {tiger, forest, fish}

1) เขียน doc. kw ex. bird → cat, fish, house, kitchen, kitty, tiger

ex. fish → bird, cat, forest, kitty, tiger

2) หา doc. kw ex. bird, cat = $2 / (2+3-2) = 0.67$

โดยกฎ doc. bird, fish = $1 / (2+2-1) = 0.33$

3) 9 Query ต่อมา

ในนี้

cat, kitty, dog

	Cat	Kitty	Dog
D1	1	1	0.25
D2	1	0.67	1
D3	1	1	0.33
D4	0.25	0.33	1
D5	0.50	0.33	0.25

	bird	cat	dog	fish	forest	house	kitchen	kitty	rubber	tiger	zoo
bird	1.00	0.67	0.00	0.33	0.00	0.33	0.50	1.00	0.00	0.25	0.00
cat	0.67	1.00	0.25	0.25	0.00	0.25	0.33	0.67	0.00	0.50	0.33
dog	0.00	0.25	1.00	0.00	0.00	0.33	0.00	0.00	0.50	0.25	0.50
fish	0.33	0.25	0.00	1.00	0.50	0.00	0.00	0.33	0.00	0.67	0.00
forest	0.00	0.00	0.00	0.50	1.00	0.00	0.00	0.00	0.00	0.33	0.00
house	0.33	0.25	0.33	0.00	0.00	1.00	0.50	0.33	0.50	0.00	0.00
kitchen	0.50	0.33	0.00	0.00	0.00	0.50	1.00	0.50	0.00	0.00	0.00
kitty	1.00	0.67	0.00	0.33	0.00	0.33	0.50	1.00	0.00	0.25	0.00
rubber	0.00	0.00	0.50	0.00	0.00	0.50	0.00	0.00	1.00	0.00	0.00
tiger	0.25	0.50	0.25	0.67	0.33	0.00	0.00	0.50	0.00	1.00	0.33
zoo	0.00	0.33	0.50	0.00	0.00	0.00	0.00	0.00	0.33	1.00	1.00

เอกสารมี kw นั้น = 1 , ไม่มี บทความที่ doc Cij มากกว่า
เทียบกับ kw ใน doc นั้น

4) Query = (cat OR kitty) AND not dog แล้วหา Ranking โดยใช้สูตร

∴ Ranking = $(1 - (1 - \mu_{cat}) \cdot (1 - \mu_{kitty})) \cdot (1 - \mu_{dog})$

ex. Doc1 = $(1 - (1 - 1)(1 - 1)) \cdot (1 - 0.25) = 0.75$

5) Ranking จากค่าจากสูตร

Extend Boolean Model → kw ไม่สัมพันธ์ , เป็น Boolean

$tf_{norm,ij} = \frac{tf_{ij}}{tf_{max,j}}$ | $idf_{norm,i} = \frac{idf_i}{idf_{max,i}}$

$\text{sim}(q_{or}, d_j) = \sqrt{\frac{w_{ij}^2 + w_{kj}^2}{2}}$ | $\text{sim}(q_{and}, d_j) = 1 - \sqrt{\frac{(1 - w_{ij})^2 + (1 - w_{kj})^2}{2}}$

ex. Query = ไขว่คว้าหาเอกสารที่มี cat และ dog และไม่มี tiger

1) สืบค้นจาก Doc เพื่อหา doc

2) คำนวณ tf , idf_{norm} รวม doc

ex. $tf_{bird} = 3/3 = 1$

$tf_{cat} = 2/3 = 0.667$

ex. $idf_{bird} = \log(10/5) = 0.301$

$idf_{norm} \text{ bird} = 0.301 / 0.301 = 1$

รวม doc แล้ว

3) หา w_{ij} แล้ว doc ex. $w_{bird1} = 1 \times 1 = 1$

$w_{cat1} = 0.667 \times 0.323 = 0.215$

	Bird	Cat	Dog	Tiger
Doc1	1.000	0.215	0.343	0.000
Doc2	0.000	0.322	0.257	0.257
Doc3	1.000	0.000	0.257	0.000
Doc4	0.000	0.322	0.000	0.515
Doc5	0.000	0.107	0.172	0.515
Doc6	1.000	0.215	0.000	0.343
Doc7	1.000	0.322	0.515	0.515
Doc8	1.000	0.322	0.515	0.000
Doc9	0.000	0.322	0.515	0.515
Doc10	0.000	0.000	0.000	0.515

↓

4) หา sim โดยใช้จาก Query

↳ (cat AND dog) AND NOT tiger

หาในตาราง doc

$\text{sim}(q_{and}, d_j) = 1 - \sqrt{\frac{(1 - \sqrt{\frac{(1 - w_{cat})^2 + (1 - w_{dog})^2}{2}})^2 + (1 - (1 - w_{tiger}))^2}{2}}$

$\text{sim}(q_{and}, d_1) = 1 - \sqrt{\frac{(1 - \sqrt{\frac{(1 - 0.215)^2 + (1 - 0.343)^2}{2}})^2 + (1 - (1 - 0))^2}{2}}$

= 0.488

5) Ranking ด้วย sim จากสูง

Generalizes Vector Space Model

↳ km ไม่โอเวอร์ฟิต, สอดคล้อง, เปรียบเทียบ km ด้วยกัน ตามทฤษฎีเริ่มต้นก็โอเวอร์ฟิต

$$k_i = \frac{\sum_{r \in q_i(m_r)} C_{ir} m_r}{\sqrt{\sum_{r \in q_i(m_r)} C_{ir}^2}} \quad C_{ir} = \sum w$$

↳ i คือ km ที่ r คือ query m

$$\text{sim}(q, d_j) = \frac{\sum S_{dr} \cdot S_{qr}}{\sqrt{\sum S_{dr}^2 \cdot \sum S_{qr}^2}}$$

ex. Query = "cat cat cat dog dog tiger"

- 1) ทำเหมือน VSM อาจจะมีค่าที่ต่างกันบ้าง
- 2) เริ่มที่ tf, idf
- 3) หา weight ทุก doc
- 4) หา weight query
- 5) แบ่งกลุ่ม doc, km ปรากฏเหมือนกัน = กลุ่มเดียวกัน

	Bird	Cat	Dog	Tiger	
Doc1	0.398	0.031	0.103	0.000	m1
Doc2	0.000	0.046	0.077	0.111	m2
Doc3	0.398	0.000	0.077	0.000	m3
Doc4	0.000	0.046	0.000	0.222	m4
Doc5	0.000	0.015	0.052	0.222	m2
Doc6	0.000	0.046	0.000	0.222	m4
Doc7	0.398	0.046	0.155	0.000	m1
Doc8	0.398	0.046	0.155	0.000	m1
Doc9	0.000	0.046	0.155	0.222	m2
Doc10	0.000	0.023	0.000	0.222	m4
Q	0	0.523	0.552	0.537	

ex. m1 = (1, 1, 0, 0)
m2 = (0, 1, 1, 1)
m3 = (1, 0, 1, 0)
m4 = (0, 1, 0, 1)

6) คำนวณหา k_i โดยดูจาก km ที่ใช้ตัว km (4 ตัว)

$$\text{ex. } k_1 = \frac{C_{11} m_1 + C_{13} m_3}{\sqrt{C_{11}^2 + C_{13}^2}} = \frac{1.194 m_1 + 0.398 m_3}{\sqrt{1.194^2 + 0.398^2}} = 0.949 m_1 + 0.316 m_3$$

$C_{11} = W_{11} + W_{13} + W_{18} = 0.398 + 0.398 + 0.398 = 1.194$
 $C_{13} = W_{13} = 0.398$

7) แทนสมการ k แต่ละตัวลงใน Query

$$q = 0.523 k_2 + 0.552 k_3 + 0.537 k_4$$

$$q = 0.523(0.615 m_1 + 0.538 m_2 + 0.576 m_4) + 0.552 k_3 + 0.537 k_4$$

$$q = 0.771 m_1 + 0.934 m_2 + 0.084 m_3 + 0.714 m_4$$

8) แทนสมการ k แต่ละตัวลงใน Doc แต่ละตัว

$$\text{ex. } d_1 = 0.398 k_1 + 0.031 k_2 + 0.103 k_3$$

$$d_1 = 0.480 m_1 + 0.074 m_2 + 0.142 m_3 + 0.018 m_4$$

	m1	m2	m3	m4
Doc1	0.480	0.074	0.142	0.018
Doc2	0.091	0.139	0.012	0.112
Doc3	0.441	0.043	0.138	0.000
Doc4	0.028	0.167	0.000	0.197
Doc5	0.051	0.179	0.008	0.179
Doc6	0.028	0.167	0.000	0.197
Doc7	0.532	0.111	0.149	0.026
Doc8	0.532	0.111	0.149	0.026
Doc9	0.154	0.253	0.024	0.197
Doc10	0.014	0.154	0.000	0.184
Q	0.771	0.934	0.084	0.714

9) หาค่า sim ของแต่ละ doc

$$\text{ex. } \text{sim}(q, d_1) = \frac{(0.480 \times 0.771) + (0.774 \times 0.934) + \dots + (0.018 \times 0.714)}{\sqrt{(0.480^2 + 0.774^2 + \dots) \times (0.771^2 + 0.934^2 + \dots)}} = 0.974$$

10) Ranking ค่าใน sim จากสูง

Probabilistic Model → user marked > km, ไม่สนใจ tf, idf

$$P(k_i | R) = \frac{r_i + 0.5}{R + 1} \quad P(\bar{k}_i | R) = \frac{n_i - r_i + 0.5}{N - R + 1}$$

$$P(\bar{k}_i | R) = R - r_i / R \quad P(\bar{k}_i | \bar{R}) = \frac{(N - R) - (n_i - r_i)}{N - R}$$

$$P(k_i | R) + P(\bar{k}_i | R) = 1 \quad P(k_i | \bar{R}) + P(\bar{k}_i | \bar{R}) = 1$$

r_i = จำนวนเอกสารที่มี km i แล้วตรงประเด็น | N = All เอกสาร
 n_i = จำนวนเอกสารที่มี km i ทั้งหมด | R = All เอกสาร R

$$\text{similarity : } \text{sim}(d_j, q) = \frac{P(R | d_j)}{P(R | \bar{d}_j)} = \frac{P(d_j | R) \times P(R)}{P(d_j | \bar{R}) \times P(\bar{R})}$$

- 1) User อาจใส่ Query เข้ามาแล้ว mark ว่าเอกสารไหนตรงประเด็น
- 2) แบ่งเอกสารที่ Relevance & Non R

ex. Relevance	Non Relevance	
$d_1 = \{1, 1\}$	$d_4 = \{1, 0\}$	$k_1 = \text{cat}, k_2 = \text{dog}$
$d_2 = \{1, 1\}$	$d_6 = \{0, 1\}$	$N = 9$
$d_3 = \{1, 0\}$	$d_7 = \{0, 1\}$	$R = 5$
$d_5 = \{1, 0\}$	$d_9 = \{0, 1\}$	$\bar{R} = 4$
$d_8 = \{0, 1\}$	$k_1 = 1$	$k_1, N = 5$
$k_1 = 4$	$k_2 = 3$	$k_1, R = 4$
$k_2 = 3$		$k_1, \bar{R} = 1$
		$\bar{k}_1, R = 1$
		$\bar{k}_1, \bar{R} = 3$
		$k_2, N = 6$
		$k_2, R = 3$
		$k_2, \bar{R} = 3$
		$\bar{k}_2, R = 2$
		$\bar{k}_2, \bar{R} = 1$

3) หา Prob ของแต่ละ km

$$P(k_1 | R) = \frac{4}{5} \quad P(k_2 | R) = \frac{3}{5}$$

$$P(\bar{k}_1 | R) = \frac{1}{5} \quad P(\bar{k}_2 | R) = \frac{2}{5}$$

$$P(k_1 | \bar{R}) = \frac{1}{4} \quad P(k_2 | \bar{R}) = \frac{3}{4}$$

$$P(\bar{k}_1 | \bar{R}) = \frac{3}{4} \quad P(\bar{k}_2 | \bar{R}) = \frac{1}{4}$$

Binary Independence Retrieval Model

4) หา sim ของแต่ละ pattern km มี 2 แบบ Simple, BIR

$$\text{simple : } P(R | (1, 1)) = \frac{2}{2} = 1$$

$$P(R | (1, 0)) = \frac{2}{3} = 0.66$$

$$P(R | (0, 1)) = \frac{1}{4} = 0.25$$

$$\text{BIR : } \text{sim}(d_1, q) = \frac{P(k_1 | R) \times P(k_2 | R) \times P(R)}{P(k_1 | \bar{R}) \times P(k_2 | \bar{R}) \times P(\bar{R})} = \frac{\frac{4}{5} \times \frac{3}{5} \times \frac{5}{4}}{\frac{1}{4} \times \frac{3}{4} \times \frac{5}{4}} = \frac{16}{5}$$

$$\text{sim}(d_3, q) = \frac{P(k_1 | R) \times P(\bar{k}_2 | R) \times P(R)}{P(k_1 | \bar{R}) \times P(\bar{k}_2 | \bar{R}) \times P(\bar{R})} = \frac{\frac{4}{5} \times \frac{2}{5} \times \frac{5}{4}}{\frac{1}{4} \times \frac{1}{4} \times \frac{5}{4}} = \frac{32}{5}$$

เนื่องจาก ทำจนครบทุก pattern นำไปใส่สูตร $\text{sim}(d_j, q) = \frac{\text{sim}(d_j, q)}{1 + \text{sim}(d_j, q)}$

$$\text{ex. } \text{sim}(d_1, q) = \frac{16}{5} \rightarrow \frac{16/5}{1 + 16/5} = \frac{16}{21} = 0.762$$

ทำจนครบทุก pattern

ex. ถ้าได้เป็นแบบนี้

	(1, 1)	(1, 0)	(0, 1)	(0, 0)
Simple	0.800	0.667	0.500	0.333
BIR	0.757	0.690	0.483	0.400

Extend Prob. Model (BM25)

↳ idf , tf_{doc} , tf_{query}

$$sim_{bm25}(d_i, q_j) = \sum idf \times tf_{doc} \times tf_{query}$$

$$Inverse\ doc.\ freq.: idf_i = \log \frac{(r_i + 0.5) / (R - r_i + 0.5)}{(n_i - r_i + 0.5) (N - n_i - R + r_i + 0.5)}$$

$$doc.\ term\ freq.: tf_{doc} = \frac{(k_1 + 1) f_i}{k_1 (1 - b) + b \times dl / avdl + f_i}$$

$$query\ term\ freq.: tf_q = \frac{(k_2 + 1) q_j}{k_2 + q_j}$$

ค่าคงที่ต่างๆ : $k_1 \approx 1.25$, $k_2 \approx 200$, $b \approx 0.75$

dl = คน.คำเอกสาร j | f → "ปรากฏในเอกสารที่สนใจ"
 $avdl$ = คน.คำเฉลี่ยของทุกเอกสาร

ex Query = Honda, Toyota, Isuzu

f	Honda	Toyota	Isuzu
d1	0	3	6
d2	0	4	0
d3	6	2	0
d4	0	2	3
d5	1	3	0
d6	3	3	3
d7	2	2	3
d8	3	4	1

① คำนวณ term freq.

② คำนวณ dl , $avdl$ จากโจทย์ (อาจต้องเขียนต่อ)

d1	My father is thinking about the car that she want to buy between Isuzu D-MAX X-series, Isuzu D-MAX V-Cross 4 door, Isuzu D-MAX V-Cross 2 door, Isuzu Mu-7, Isuzu Mu-X, Isuzu D-MAX H-Lander, Toyota Hilux vigo, Toyota Hilux revo or Toyota Innova.
d2	My uncle suggest My father that he should buy Toyota camry, Toyota vico, Toyota yaris or Toyota corolla altis.
d3	My mother will buy a car for me and my brother, we think we should Honda city, Honda brio, Honda CR-V, Honda BR-V, Honda civic, Honda accord, Toyota Yaris, Toyota vico.

ex. $dl = 42$, $d2 = 19$...

$$AVR = \frac{42 + 19 + \dots}{n} = 32.5$$

โดยที่ R ไม่ใน R
 (ไม่จำเป็นด้วย) ถ้าใน R , r_i เป็น 0

③ หา idf ของ bm จากข้อมูลรวม

$$R = 5 \quad N = 8 \quad ex. idf_H = \log \frac{(5+0.5)/(5-5+0.5)}{(5-5+0.5)/(8-5-5+0.5)} = 1.89$$

④ หา sim ของ doc . ที่ต้องการ (อาจเป็นเอกสารที่สนใจอยู่ในระบบ)

	ความถี่ Honda	ความถี่ Toyota	ความถี่ Isuzu	จำนวนคำในเอกสาร
d10	0	4	2	21
d20	9	15	2	55
d30	11	7	5	35
d40	6	6	6	25

เป็น 1 เทอร์ม query มีของ $R = 1$

$$ex. sim_{bm25}(d_{30}, q) = 1.89 \times \frac{(2.25) 11}{1.25 ((1-0.75) + 0.75 (\frac{35}{32.5})) + 11} \times \frac{(200+1)}{(200+1)} + 0.2 \times \frac{(2.25) 7}{1.25 ((1-0.75) + 0.75 (\frac{35}{32.5})) + 7} \times 1 - 0.08 \times \frac{(2.25) 5}{1.25 ((1-0.75) + 0.75 (\frac{35}{32.5})) + 5} \times 1 = 3.789 + 0.341 - 0.135 = 4.026$$

	ความถี่ Honda	ความถี่ Toyota	ความถี่ Isuzu	จำนวนคำในเอกสาร	sim
d30	11	7	5	35	4.026
d40	6	6	6	25	3.852
d20	9	15	2	55	3.810
d10	0	4	2	21	0.242

⑤ Ranking ตาม sim มาจาก

Evaluate → ประเมินค่าของประเด็น model

	Relevant	Not relevant
Retrieved	A	B
Not retrieved	C	D

$$recall = \frac{\text{คน. doc ที่สนใจ} + \text{Relevant}}{\text{คน. doc All Relevant}} = \frac{A}{A+C}$$

$$precision = \frac{\text{คน. doc ที่สนใจ} + \text{Relevant}}{\text{คน. doc All ที่สนใจ}} = \frac{A}{A+B}$$

$$miss = C/A+C$$

ex. ① หา Precision และ Recall จากลำดับเอกสาร

n	doc #	relevant
1	588	x
2	589	x
3	576	
4	590	x
5	986	
6	592	x
7	984	
8	988	
9	578	
10	985	
11	103	
12	591	
13	772	x
14	990	

$$P = 1/5 \quad P = 1/1 = 1$$

$$P = 2/5 \quad P = 2/2 = 1$$

$$P = 3/5 \quad P = 3/4 = 0.75$$

$$P = 4/5 \quad P = 4/6 = 0.67$$

$$P = 5/5 \quad P = 5/13 = 0.38$$

$$② \text{หา Avg Precision} \rightarrow \frac{1+1+\dots+0.38}{5} = 0.76 = 76\%$$

ของแต่ละ model แล้ว $R=1$

③ คำนวณ Avg Precision

R-Precision → q Top Rank, รวมจนเอกสารที่สนใจ

ex. $P = \# \text{ of relevant docs} = 5$

$$R\text{-Precision} = 3/5 = 0.6$$

Precision Histograms : $RP_{A/B}(i) = RP_A(i) - RP_B(i)$

$$= 60\% - 80\% = -20\%$$

$$F\text{-Measure} : F = \frac{2PR}{P+R} = \frac{2}{1/P + 1/R}$$

E-Measure → ให้คำนวณได้ทั้งจาก P หรือ R มาจาก

$$E = \frac{(1 + \beta^2) PR}{\beta^2 P + R} = \frac{(1 + \beta^2)}{\frac{\beta^2}{P} + \frac{1}{R}}$$

User-Oriented Measure

$$Coverage = |R_k| / |U|$$

$$Novelty = |R_u| / (|R_u| + |R_k|)$$

Fallout → ปล่อยให้ Recall และ Precision : $\frac{\text{คน. non rel ที่ออก}}{\text{All คน. non rel}}$

Query Operations → ทำกับ Query ของระบบเดิมมากขึ้น

Relevance Feedback → 1. user feedback (explicit feedback)

2. automatically (implicit feedback)

Query Reformulation ปรับ Query

- Query Expansion เพิ่ม terms ของ R

- Term Reweighting เพิ่ม weight ของ term

Vector Space Re-weighting

$$L_{Rocchio} = \alpha Q + \frac{\beta}{n_1} \sum_{d_j \in D_1} \vec{d}_j - \frac{\gamma}{n_2} \sum_{d_j \in D_n} \vec{d}_j$$

$$Q_0 = \text{vector initial } Q \quad \alpha = 1, \beta = 0.75, \gamma = 0.25$$

D_r = set R docs

D_n = set $\bar{R}$ docs

n_1 = คน. R ที่ถูกเลือก

n_2 = คน. $\bar{R}$ ที่ถูกเลือก

$$ex. R_1 = (0.03, 0, 0.025), R_2 = (0.02, 0.09, 0.02)$$

$$S_1 = (0.03, 0.01, 0.02), Q = (0, 0, 0.5)$$

$$Q_{new} = \alpha \times Q + \left(\frac{\beta}{2} (R_1 + R_2) \right) - \left(\frac{\gamma}{1} (S_1) \right) = (0.011, 0.000875, 0.002)$$

$$L_{Ide\ Regular\ Method} : \vec{q}_1 = \alpha \vec{q}_0 + \beta \sum_{d_j \in D_1} \vec{d}_j - \gamma \sum_{d_j \in D_n} \vec{d}_j$$

$$ex. \text{Original Query} = (5, 0, 3, 0, 1), \alpha = 0.5, \beta = 0.25$$

$$\text{Doc. } D_1 \text{ Relevant} = (2, 1, 2, 0, 0), \text{Doc. } D_2 \text{ NonRel.} = (1, 0, 0, 0, 2)$$

$$q' = q + 0.5 D_1 - 0.25 D_2$$

$$= (5, 0, \dots) + 0.5 (2, 1, 2, \dots) - 0.25 (1, 0, \dots) = (5.75, 0.5, \dots)$$

Automatic Global Analysis → หา itf แทนที่จ.เป็น idf

การหา itf เป็น key/doc →

$$idf_j = \log \frac{1}{t_j} \quad \text{ที่ } t = \text{Term} = \text{key ใน doc}$$

weight ของ doc : $W_{ij} = \frac{(0.5 + 0.5 \frac{f_{ij}}{\max_j(f_{ij})}) idf_j}{\sum_k (0.5 + 0.5 \frac{f_{ik}}{\max_k(f_{ik})})^2 idf_k^2}$

sim ของ doc : $C_{uv} = \bar{t}_u \cdot \bar{t}_v = \sum_{j=1} W_{uj} \times W_{vj}$

sim ของ doc : $sim(q, k_v) = \bar{q} \cdot \bar{k}_v = \sum_{u \in q} W_{uq} \times C_{uv}$

weight ของ query : $W_{uq} = \frac{sim(q, k_v)}{\sum_{u \in q} W_{uq}}$

sim ของ doc : $sim(q, d_j) \propto \sum_{k \in d_j} \sum_{u \in q} W_{uj} \times W_{uq} \times C_{uv}$

ex. Query = 2.3A + C

Key/Doc	D1	D2	D3	D4
A	3	0	0	1
B	2	0	1	0
C	1	1	0	0
D	0	2	0	1
E	0	0	2	1
Max	3	2	2	1
$\frac{1}{t_j}$	3	2	2	3
idf(Doc)	0.222	0.398	0.398	0.222

① สร้างตารางและหา itf ของทุกเอกสาร

ex. Term = 5
 $idf_4 = \frac{5}{3} = 0.222$

② หา W_{ij} ของ doc ในแต่ละ doc ในบรรทัดข้อ ๑

ex. $W_{1,3} = \frac{(0.5 + 0.5 \frac{f_{1,3}}{\max_j(f_{1j})}) idf_3}{\sqrt{(0.5 + 0.5 \frac{f_{1,1}}{\max_j(f_{1j})})^2 idf_1^2 + (0.5 + 0.5 \frac{f_{1,2}}{\max_j(f_{1j})})^2 idf_2^2 + \dots}}$
 $= \frac{(0.5 + 0.5 \frac{0}{2}) 0.398}{(0.5 + 0.5 \frac{3}{3})^2 (0.222)^2 + (0.5 + 0.5 \frac{0}{2})^2 (0.398)^2 + \dots}$
 $= 1.509$

③ หาค่า sim. ระหว่าง doc ในบรรทัดข้อ ๑, ๓

ex. $C_{1,3} = W_{1,1}W_{3,1} + W_{1,2}W_{3,2} + W_{1,3}W_{3,3} + W_{1,4}W_{3,4}$
 $= 1.683(0.996) + 1.509(2.01) + 1.509(1.34) + 1.683(0.747)$
 $= 7.987$

④ ถ้าจะใช้ doc ในบรรทัดข้อ ๑ แทนที่ sim(q, k_v)

ex. $sim(q, k_3) = W_{1,q}C_{1,3} + W_{2,q}C_{2,3} + W_{3,q}C_{3,3} + \dots + W_{5,q}C_{5,3}$
 $= 2.3(7.987) + 1(7.383) = 25.753$

ex. $sim(q, k_3) = 2.3(7.987) + 1(7.085) + 1(7.383) = 32.838$

⑤ ถ้าหา weight ของ doc ที่ใช้ query
ex. $q = 2.3K_1 + K_2 + K_3$
sum query weight = 2.3 + 1 + 1 = 4.3

$W_{1,q} = 39.780 / 4.3 = 9.251$
 $W_{2,q} = 33.887 / 4.3 = 7.881$
 $W_{3,q} = 32.838 / 4.3 = 7.637$

⑥ หา sim ของ doc โดยการใช้ W. query, W. doc, C_{uv}

ex. $sim(q, d_3) = W_{1,2}W_{1q}(C_{1,1} + C_{1,2} + C_{1,3} + C_{1,4} + C_{1,5}) + W_{2,2}W_{2q}(C_{2,1} + C_{2,2} + \dots + C_{2,5}) + W_{3,2}W_{3q}(C_{3,1} + C_{3,2} + \dots + C_{3,5})$
 $= 1931.123$

⑦ Ranking ตามค่า sim จากข้อ ๑

Automatic Local Analysis

มี 3 วิธี → association clusters, metric clusters, scalar clusters

Association Clusters → หาจาก doc. ของ doc

doc. ของ doc : $C_{u,v} = \sum_{d_j \in d_i} f_{s_{u,j}} \times f_{s_{v,j}}$

normalized Corr. Matrix : $S_{u,v} = \frac{C_{u,v}}{C_{u,u} + C_{v,v} - C_{u,v}}$

ex. Query = A+B

① เขียนตารางจากข้อ ๑

ex. $d_1 = A, A, B, P$
 $d_2 = B, A, C, C, D$

	d ₁	d ₂	d ₃	d ₄	d ₅	d ₆	d ₇
A	2	1	1	0	0	1	1
B	1	1	1	1	0	1	2
C	0	2	0	1	0	0	0
D	1	1	0	1	1	1	0

② หา C_{u,v}

	A	B	C	D
A	8	7	2	4
B	7	9	3	4
C	2	3	5	3
D	4	4	3	5

ex. $C_{1,4} = (f_{1,1}f_{4,1}) + (f_{1,2}f_{4,2}) + (f_{1,3}f_{4,3}) + \dots + (f_{1,7}f_{4,7})$
 $= (2 \times 1) + (1 \times 1) + (1 \times 0) + (0 \times 1) + (0 \times 1) + (1 \times 1) + (1 \times 0)$
 $= 4$

③ Normalized Corr. Matrix

ex. $S_{1,2} = \frac{4}{8+9-7} = 0.7$

	A	B	C	D
A	1	0.70	0.18	0.44
B	0.70	1	0.27	0.40
C	0.18	0.27	1	0.43
D	0.44	0.40	0.43	1

④ หา doc Query ในบรรทัดข้อ ๑

ex. Term Relation
A → {A, B}
B → {B, A}
C → {C, D}
D → {D, A}
ex. $q = A+B \rightarrow q' = (A+0.7B) + (0.7A+B)$
 $= 1.7A + 1.7B$
 $= A+B$ (เท่ากับ doc เดิม)
ex. $q = C+2D \rightarrow q' = (C+0.43D) + (0.43B + 0.43C + D)$
 $= 0.43B + 1.43D$

Metric Clusters → หาจาก distance ของ doc, ทำ stem

doc. ของ stem : $C_{u,v} = \sum_{k \in (s_u)} \sum_{k' \in (s_v)} \frac{1}{r(k, k')}$

Normalized Corr. Matrix : $S_{u,v} = \frac{C_{u,v}}{|V(s_u)| \times |V(s_v)|}$

ex. Query = A+2D
 $k_u = A, B, C, D, E, F$

① แบ่งรากศัพท์ (stem)

รากศัพท์	A	B	C	D	E	F
A	0	5	0	0	1	2
B	5	0	3	2	1	1
C	0	3	0	3	4	0
D	0	2	3	0	0	5
E	1	1	4	0	0	1
F	2	1	0	5	1	0

$V(s_1) = \{A, B, C\}$
 $V(s_2) = \{D, E\}$
 $V(s_3) = \{F\}$

หารายชื่อของ doc จากเอกสารที่ return ออกมา โดยยึดรากศัพท์น้อยสุด
similarity return A, B distance 5 ✓
d₅
d₆ 8

② แปลงค่าในตาราง (x) ด้วย 1/x

รากศัพท์	A	B	C	D	E	F
A	0	5	0	0	1	2
B	0.20	-	0.33	0.50	1	1
C	0	0.33	-	0.33	0.25	0
D	0	0.50	0.33	-	0	0.20
E	1	1	0.25	0	-	1
F	0.50	1	0	0.20	1	-

ex. $0 \rightarrow 1/0 = -$
 $5 \rightarrow 1/5 = 0.2$

③ หา C_{u,v} (doc. ของ stem)

ex. $C_{1,2} = C(A,D) + C(A,E) + C(B,D) + C(B,E) + C(C,D) + C(C,E)$
 $= 0 + 1 + 0.5 + 1 + 0.33 + 0.25$
 $= 3.08$

	S ₁	S ₂	S ₃
S ₁	0	3.08	1.50
S ₂	3.08	0	1.20
S ₃	1.50	1.20	0

④ Normalized Corr. Matrix

ex. $S_{2,3} = \frac{C_{2,3}}{|V(s_2)| \times |V(s_3)|} = \frac{1.2}{2 \times 1} = 0.6$

	S ₁	S ₂	S ₃
S ₁	0	0.51	0.50
S ₂	0.51	0	0.60
S ₃	0.50	0.60	0

⑤ หา Query ใหม่

ex. Stem Relation
 $s_1 \rightarrow \{s_1, s_2\}$
 $s_2 \rightarrow \{s_1, s_3\}$
 $s_3 \rightarrow \{s_3, s_2\}$
 $q = A+2D \rightarrow q' = (s_1 + 0.51s_2) + 2(s_2 + 0.5s_3)$
 $= s_1 + 2.51s_2 + 1.2s_3$

Scalar Clusters → มาจากทศ. สอดคล้อง

vector คลว. ของ stem : $\vec{S}_u = (C_{u,1}, C_{u,2}, \dots, C_{u,t})$

ขนาดของ stem : $|\vec{S}_u| = \sqrt{C_{u,1}^2 + C_{u,2}^2 + C_{u,3}^2}$

Normalized Corr. Matrix : $S_{u,v} = \frac{\vec{S}_u \cdot \vec{S}_v}{|\vec{S}_u| \times |\vec{S}_v|}$

ex. Query = $3S_1 + S_3$

① เขียน vector คลว. ของ stem

ex. $\vec{S}_1 = (C_{1,1}, C_{1,2}, C_{1,3}) = (5, 6, 1)$

Database $\vec{S}_3 = (C_{3,1}, C_{3,2}, C_{3,3}) = (1, 0, 2)$

↓ $C_{Network, Algebra}, C_{Network, Math}, C_{Network, Set}$

stem $\sim$ Network = {Set(2), Algebra(1), Math(0)}

② ขนาดของ stem

ex. $|\vec{S}_3| = \sqrt{1+0+4} = 2.236$

$|\vec{S}_1| = \sqrt{25+36+1} = 7.874$

③ use Normalized Corr. Matrix คำนวณนิโคตรของ stem

ex. $S_{1,3} = \frac{\vec{S}_1 \cdot \vec{S}_3}{|\vec{S}_1| \times |\vec{S}_3|} = \frac{(5 \times 1) + (6 \times 0) + (1 \times 2)}{7.874 \times 2.236} = 0.398$

S	S ₁	S ₂	S ₃
S ₁	1	0.986	0.398
S ₂	0.986	1	0.248
S ₃	0.398	0.248	1

④ use New Query

Stem Relation $q = 3S_1 + S_3$

$S_1 \rightarrow \{S_1, S_2\}$

$S_2 \rightarrow \{S_2, S_3\}$

$S_3 \rightarrow \{S_3, S_1\}$

↓

$q' = 3(S_1 + 0.986S_2) + (0.398S_1 + S_3)$
 $= 3.398S_1 + 2.958S_2 + S_3$

Text Operations → จัดการข้อความในแนว: กับกรณีเรียบเทียบ (doc, query)

① Lexical Analysis มาจากคำของเอกสารหรือแบบของของของ

② Elimination of stopwords

③ stemming → ขั้ว & วิกิ

↳ affix removal, table lookup, successor variety, N-gram

successor variety

ex. corpus : able, axle, accident, ape, about

test word : apple

Prefix	Successor Variety	Letters
a	4	b, x, c, P
b	2	l, o
o	1	u
u	1	t
t	1	blank

n-gram → $S = \frac{2C}{A+B}$

ex. statistics ⇒ st ta at ti is st ti ic cs

unique diagrams ⇒ at cs ic is st ta ti

statistical ⇒ st ta at ti is st ti ic ca al

unique diagrams ⇒ al at ca ic is st ta ti

$S = \frac{2(6)}{4+8}$

Affix Removal Stemmers ex. คำของ ies เปลี่ยนเป็น ies, aies

เปลี่ยน ies → y

④ Index Terms Selection → ดัชนี = คำ


Text Compression

นายวัชรชัย วรรณสินศักดิ์ 65010815

Huffman Coding → สร้าง Tree


case 1

ex. ① รวมความถี่เป็นคู่ 2 ชั้น



ส่วนน้อยไม่มากจนทำ


② ทดลองที่ได้แล้วเขียนลำดับน้อย → มาก แล้วค่อยสร้าง Post เพิ่ม loop ②




③ เขียนเลขช่วย 0, 1 แล้วเขียน code ของแต่ละตัว

case 2 → save ทำ case 1

ex. ① รวมความถี่ที่ค่าแล้วเขียนกันขึ้นจากรวม ทำส่วนเหลือ 2 กลุ่ม



② ด้อยกว่ากลายเป็น tree แล้วเขียน code ในแต่ละตัว



encode : สมมติตัวส่ง e a b a d c e d
 01 000 11 000 001 10 01 001 คิดกัน

decode : ทำกลับกัน

Ziv Lempel Welch

ex. ① เขียน P, C, P+C ถ้า input ที่ส่งตัว เขียน character เหล่านี้ใน Dict

Dictionary
1 A
2 B
3 W

Encode Text : WABBAWABBA

P : W A B B A W A B B A
 C : W A B B A W A B B A
 P+C : W A B B A W A B B A

Dictionary
1 A
2 B
3 W
4 WA
5 AB
6 BB
7 BA
8 AW
9 WAB
10 BBA

② ถ้า P+C อยู่ใน Dict : P+C → P ไม่ซ้ำ C → P แล้วเพิ่มลงใน Dict


③ ไม่ไปสื่อย่อยจนแล้ว

P : W A B B A W A B B A
 C : W A B B A W A B B A
 P+C : W A B B A W A B B A


④ เขียน Encode output จาก P เขียนใน Dict Encode : 31221461

⑤ ทำ Decode


Decode : 31221461




Decode : 31221461



Decode : 31221461



Decode : 31221461



Indexing and Searching

→ ทำในต้นฉบับได้หรือไม่ , 3 วิธี

Inverted files → เก็บ word ไว้ doc/pages (พจน.) ใน

ex. "abacus" : 3, 19, 22

↳ Block Addressing → ทำความจำแบบเป็นบล็อก


Block 1	Block 2	Block 3	Block 4
That house has a	garden. The garden has	many flowers. The flowers	are beautiful

↳ Searching

↳ Construction → ถ้ามีคำใหม่ ⇒ ต่อท้าย (add new position)

วิธีตาม Dictionary (เลขชี้แต่ 0 ถึง) จากซ้าย → ขวา ไม่เป็น "."

1 6 9 11 17 19 24 28 33 40 45 50 55 60 text



↳ เปรียบกับคอมพิวเตอร์ ไม่เปลี่ยน (≠ คอมพิวเตอร์)


Suffix Trees and Suffix Arrays

ex. เก็บตาม Dict มี "." อยู่

This is a text. A text has many words. Words are made from letters.

text. A text has many words. Words are made from letters.
 text has many words. Words are made from letters.
 many words. Words are made from letters.
 words. Words are made from letters.
 made from letters.
 letters.

Suffixes 60 50 28 19 11 40 33 Suffix Array



ex. ถ้าตัวแรกเป็น letters (60) ต่อมา ba... มาที่แรกเสร็จแล้ว (เลข) ไม่


↳ สร้าง Array เพื่อค้นหาเริ่มที่คำสุดท้ายได้ (มันย้อนมาได้)

left text word Supra-index
 60 50 28 19 11 40 33 Suffix Array

Signature Files

↳ เอา เลข ของแต่ละ Block ไปทำ Hashing function เพื่อได้ code ของ block

มี 2 ตัว ทำ hashing func. แล้วรวม OR



ex. มีวิธี Query ทำจาก Query ไปทำ hash แล้วไป AND แล้ว Block

ถ้าได้เท่าเดิม Block นั้นมี เลข ที่ตรงกัน (ถ้าได้เท่าเดิม แล้ว Block นั้นมีเลข → hash func. แยก
 ต่อเป็น 2)

Boolean Diagram

- adj มีหน้าที่ ex. abacus adj actor

- near 4 → อยู่ห่างไม่เกิน 4 คำ ex. abacus near 4 actor

Priority 1. adj, near
 2. and, not
 3. or

Brute Force

ex. Query = "for"

1 0 1 2 3 4 5 6
 brute force ใช้วิธีนี้จนเจอ
 for
 for

Boyer Moore

↳ เลื่อนตามตาราง , เลื่อนตามความยาว (length)

ex. Query = THOTH

① สร้างตาราง กฎคือ index เริ่มที่ 0 , ใช้ตัวอักษรในที่อยู่ท้ายแถวก่อน ,

ex. THOTH Value = length - index - 1

Length = 5 T = 5 - 3 - 1 = 1

H = 5 - 1 - 1 = 3

O = 5 - 2 - 1 = 2

ไม่ทำตัวสุดท้ายมาคำนวณ (ไว้ length เสร็จ)

Letter	T	H	O	.
Value	1	3	2	5

② ลงมือใช้กฎทำ doc เป็นคำเทียบกับตาราง

doc: T R U S E H A T T H O T H

a: T H O T H T H O T H T H O T H

③ ถ้าเจอแล้ว doc ย้อนกลับไปหน้า

Kruth - Morris - Pratt → ดัน้อยกว่า Boyer

คล้าย Boyer แต่ใช้กับตัวหน้า และ สร้าง ตารางจาก Prefix suffix

ex. Query = ACAGAT

i	1	2	3	4	5	6	7
Pattern[i]	A	C	A	C	A	G	T
Prefix[i]	0	0	1	2	0		

① ค่าที่ = Index แล้วจะมี Duplicate มี คำมีอะไรมาหาคู่

A Prefix: Suffix:

C Prefix: A Suffix: C

A Prefix: A, AC Suffix: A, CA

C Prefix: A, C, ACA Suffix: C, AC, CAC

A Prefix: A, AC, ACA, ACAC Suffix: A, CA, CCA, CACA

Dupe 1, Length 1

" 1, " 2

" 2, " 3

i	1	2	3	4	5	6	7
Pattern[i]	A	C	A	C	A	G	T
Prefix[i]	0	0	1	2	3	0	0

② เขียนแบบ Boyer เมเจอตัวแล้ว

Google Tech

① Crawling → ใช้ตัว google bot/spider ว่าจะทำอะไรบน web ใหญ่ , index update

มี 3 ขั้นตอน → ครอบคลุมด้วย filter, แยก/ตัดคำ , จัดอันดับ

② Page Rank → วัดค่าสำคัญของเว็บ

ค่าเลขบอกสำคัญ , 0-10 ยิ่งมาก = แสดงก่อน , ต่อ page rank ด้านหน้าจากหน้าอื่น

③ Google Query

↳ ตัดที่ต้นบางๆ จากหน้าเว็บ

↳ ผลที่ได้จากโปรแกรมตรงกับคำที่ใช้

↳ ขยายคำย่อ ex. → example

↳ ดันคำใกล้เคียง child + children

↳ stopwords ไม่ใช่เป็น the, on, where, how

↳ ทำกับ 32 คำ

↳ ลำดับคำที่จะใช้ a. ลำดับกับหน้าที่มีคำเรียงตามลำดับตรงกับที่ใช้

↳ ไม่สนใจคำบางคำในเว็บ

↳ อักษรพิเศษบางตัวไม่ใช่ แต่บางตัวใช่

↳ Apostrophes ("") จ. ดัด

↳ ถ้า "-" จะลดคำที่เพิ่มในตัวอย่าง ex. E-mail, Email, E mail